Владимир Шаклеин

mrnereof@gmail.com | t.me/mrnereof

О себе

ML Engineer с опытом проектирования и запуска production LLM-систем. Строил RAG-пайплайны и framework для оценки моделей с eval-сетами и автоматическим расчётом метрик. Работал с коммерческими и open-source LLM, разворачивал модели на собственной инфраструктуре. Руководил технической работой ML-команды и принимал решения с учётом качества моделей, стоимости инференса и влияния на продуктовые метрики; обосновывал выбор архитектуры перед руководством компании.

Опыт работы

ML Engineer Ноябрь 2025 – Сентябрь 2026

АО «Кью Групп» *Москва*

- Разработал safety layer для LLM Gateway с настраиваемыми policy checks и RAG-based механизмом обнаружения утечек корпоративных документов.
- Спроектировал и внедрил framework для оценки ML- и LLM-моделей: декларативные model configurations и eval-сеты, автоматический запуск экспериментов, расчёт метрик и аналитика результатов.
- Проводил систематическое сравнение LLM-конфигураций и выбирал модели для production по метрикам качества, стоимости и latency.
- Внедрил production-систему классификации вредоносного контента и организовал её оценку на выделенных validation/eval-наборах.
- Построил индексации корпоративных документов для использования в RAG.
- Развернул on-premise инференс open-source моделей (gpt-oss, Mistral) на собственной GPU-инфраструктуре.
- Отчитывался напрямую перед директорами компании: обосновывал выбор моделей и архитектурных решений метриками качества, стоимости инференса и влияния на продукт.

Co-Founder & Lead AI Engineer Ноябрь 2024 – Июль 2026

AI Video Generation Platform *Удалённо*

- Отвечал за архитектуру и техническое развитие платформы, обслуживающей 60k MAU и сгенерировавшей 1.8M медиафайлов.
- Руководил переходом от внешних AI-сервисов к собственным моделям: определял архитектуру и координировал работу команды ML-инженеров.
- Спроектировал распределённую GPU inference инфраструктуру и autoscaler на метриках RabbitMQ с heartbeat-механизмом для обнаружения зависших воркеров.
- Построил автоматизированный пайплайн обучения LoRA-моделей (Wan 2.2) и маркетплейс шаблонов.
- Провёл A/B-тесты продуктовых гипотез, увеличив конверсию на 20%, а ARPU — на 70%.

Python Backend Engineer Май 2022 – Май 2023

Open-source проект RuFoundation *Удалённо*

- Спроектировал и запустил backend open-source вики-движка, совместимого с Wikidot; оптимизировал критические части парсера и рендеринга на Rust.

Python / AI Backend Engineer Апрель 2022 – Октябрь 2022

ООО «ГРААЛЬ Групп» *Удалённо*

- Разработал LLM-агента для автоматизации продаж на собственной инфраструктуре: мониторинг чатов, ведение диалога, отправка материалов и передача обращения менеджеру.
- Внедрил систему в двух компаниях-клиентах; для второго клиента реализовал интеграцию API для расчёта стоимости доставки по адресу.

Проекты

Dashgram | *FastAPI, Go, PostgreSQL, ClickHouse, Kafka* Июнь 2025 – Июль 2026

- Выступал архитектором и backend-разработчиком сервиса аналитики для Telegram-ботов и Mini Apps.
- Реализовал масштабируемый event-driven пайплайн на Kafka для сбора и асинхронной обработки событий из нескольких источников.

TripTuner | *FastAPI, MongoDB, RabbitMQ, ElasticSearch* Январь 2025 – Май 2025

- Выступал архитектором и backend-разработчиком сервиса рекомендаций маршрутов прогулок по Москве на основе пользовательских предпочтений.
- Разработал retrieval-пайплайн, преобразующий пользовательский запрос в параметры маршрута с помощью BERT и LLM и подбирающий релевантные локации.

Styllz | *FastAPI, MongoDB, Stable Diffusion, DreamBooth* Апрель 2023 – Июль 2023

- Разработал backend для сервиса виртуальной примерки одежды и реализовал автоматизированное дообучение модели для каждого пользователя.
- MVP вышел в финал международной премии стартап-проектов «Искусный интеллект 2023».

Образование

Прикладная математика и информатика Бакалавриат

Факультет компьютерных наук *НИУ «Высшая школа экономики», Москва*

Технические навыки

Языки: Python, Go, SQL, Rust, C++
LLM: LangChain, RAG, LoRA, LLM-as-a-judge, prompt engineering, eval-сеты, agents
ML: PyTorch, scikit-learn, BERT, fine-tuning, embeddings, vector search
Backend и данные: FastAPI, ElasticSearch, PostgreSQL, ClickHouse, Kafka, RabbitMQ, Redis, S3
Инфраструктура: vLLM, Docker, Prometheus, Grafana, CI/CD, Git
Английский: B2 — Upper-Intermediate